Hochschule
Bonn-Rhein-Sieg
University of Applied Sciences

Leistungsbeschreibung

KI-Demonstrator zur finanziellen Bildung im Forschungsprojekt MINTIFY

Vergabenummer 2065458

Inhalt

1. Einführung 3
2. Leistungsanforderungen 3
2.1 Open Source, EU-Cloud und On-Premise 3
2.2 Cloud-Infrastruktur 3
2.3 Sprachmodell & RAG-Datenbank 4
2.4 Benutzeroberfläche 4
2.5 Admin-Oberfläche (Administrator) 6
2.6 Weitere mögliche Weiterentwicklungen 7
3. Zeit- und Budgetanforderungen 7
3.1 Phasenplan und Budget 7
3.2 Support und Gewährleistung im Rahmen des Projekts 8
4. Anforderungen an das Angebot 8
5. Vertragsbedingungen 8
6. Zuschlagskriterien 9

1. Einführung

Im Rahmen des Drittmittelprojekts „MINTIFY“ an der Hochschule Bonn-Rhein-Sieg soll ein KI-gestützter Demonstrator zur Förderung der finanziellen Bildung von Bürgerinnen und Bürgern entwickelt werden. Mit seiner Hilfe soll untersucht werden, wie künstliche Intelligenz in Lern- und Alltagssituationen eingesetzt werden kann, um Finanzwissen zu vermitteln. Kern des Systems ist die Nutzung von Open-Source-Sprachmodellen (LLMs), die über ein Chat-Interface sowohl Text- als auch Sprach-Ein- und -Ausgaben ermöglichen. Nutzerinnen und Nutzer können Anfragen stellen, die anhand hinterlegter Bildungsinhalte oder durch Internetsuchen beantwortet werden.

Das Forschungsprojekt „MINTIFY“ ist Teil des Rahmenprogramms Empirische Bildungsforschung des BMBF/BMFSFJ.

2. Leistungsanforderungen

2.1 Open Source, Cloud und On-Premise

Gegenstand der Leistung ist die Entwicklung und Bereitstellung eines KI-Demonstrators zur finanziellen Bildung. Das System muss vollständig aus Open-Source-Komponenten bestehen und folgende Eigenschaften aufweisen:

- Bereitstellung von zwei leistungsfähigen Opens-Source-Sprachmodellen (LLM) – ein primäres sowie ein zweites zum Vergleich. Beide LLMs dürfen weder proprietäre Lizenzen noch Nutzung von proprietärer Cloud-Diensten voraussetzen.
- Parallele Nutzung beider Modelle (sequenziell auf derselben GPU) über eine einheitliche Plattform.
- Nutzung möglichst europäischer Cloud-Infrastruktur.
- Zudem eine On-Premise-Installation auf einem leistungsstarken Laptop (z. B. MacBook Pro M4 Max mit 40-Core-GPU und 64 GB RAM) (nur Interferenz).
- Alle entwickelten Artefakte – einschließlich Quellcode, Modelle und Benutzeroberfläche – sind in einem öffentlichen Software-Repository bereitzustellen. Sämtliche Komponenten sind vollständig unter einer MIT- oder Apache-2.0-Lizenz zu veröffentlichen. Abweichungen hiervon (z. B. durch Verwendung einer BSD-3-Clause-Lizenz) sind im Angebot ausdrücklich zu kennzeichnen und zu begründen. Die Veröffentlichung erfolgt unter Angabe der Hochschule als Auftraggeberin sowie mit einem Hinweis auf die Förderung.

2.2 Cloud-Infrastruktur

Der Auftragnehmer stellt für den Zeitraum März 2026 – Januar 2028 eine leistungsfähige Cloud-Infrastruktur bereit. Diese ist in einem zertifizierten Rechenzentrum zu betreiben, das sich vorzugsweise innerhalb der Europäischen Union befindet. Es sind folgende Mindestanforderungen zu erfüllen:

- Bereitstellung von GPU-Servern zur Ausführung der Sprachmodelle. Erwartet werden ca. 3 gleichzeitige Nutzer.

- Inklusive Speicherplatz für alle entwickelten Modelle, Trainingsdaten und Benutzerdateien. Die Benutzerdateien werden in Summe 1 TB nicht überschreiten.
- Verfügbarkeit über den gesamten Projektzeitraum; Wartungsfenster müssen im Voraus angekündigt werden.
- Installation von zwei Testgeräten (Bring-Your-Own-Device) zur lokalen Ausführung der Modelle des Systems
- Gesamtkosten der Cloud-Infrastruktur über den Projektzeitraum sind im Gesamtbudget zu kalkulieren.

2.3 Sprachmodell & RAG-Datenbank

Der Demonstrator basiert auf mindestens zwei Open-Source-Sprachmodellen. Die Modelle sollen speziell auf Inhalte zur finanziellen Bildung und auf die Anforderungen der Hochschule angepasst werden. Der Anbieter hat einschlägige Erfahrung im Training und Fine-Tuning von Sprachmodellen nachzuweisen und muss mindestens drei Referenzprojekte zur Open-Source-KI-Systementwicklung belegen. Die Leistung umfasst:

- Auswahl, Anpassung und Optimierung von zwei geeigneten Open-Source-Modellen (z. B. Qwen-3 oder Gemma-3).
- Das Training und die Inferenz sind möglichst ressourcenschonend zu gestalten. Ziel ist ein effizienter Betrieb auch auf vergleichsweise kleiner Hardware (GPUs), beispielsweise NVIDIA RTX 4090, RTX 6000 oder A100.
- Durchführung von domänenspezifischen Fine-Tunings auf den Kontext der finanziellen Bildung.
- Integration von Text-to-Text-, Speech-to-Text-, Text-to-Speech und Speech-to-Speech-Interaktion.
- Implementierung einer Retrieval-Augmented-Generation (RAG)-Datenbank zur Einbindung benutzerspezifischer Dateien als Hintergrundwissen.
- Bereitstellung der trainierten Modelle inklusive vollständiger Dokumentation und offener Lizenz zur Nutzung und Weiterentwicklung durch die Hochschule.

2.4 Benutzeroberfläche

Es soll eine Web-Oberfläche entwickelt werden, die die Interaktionsmöglichkeit mit dem System für Nutzende darstellt. Sie muss in deutscher Sprache ausgeliefert werden und folgende Funktionen bereitstellen:

- Login-geschützter Zugang: Chats und Daten sind pro Nutzerkonto getrennt zugreifbar und sind ebenfalls getrennt gespeichert.
- Chat-Bereich: Text-to-Text-, Speech-to-Text-, Text-to-Speech und Speech-to-Speech-Kommunikation sowie Mischformen; der Chatverlauf wird übersichtlich im mittleren Bereich dargestellt (siehe Abbildung 1).
- Chat-Modi: Es können verschiedene Nutzungs-Modi vom Nutzer ausgewählt werden. Diese sind als Schieberegler zentriert über dem Chat auswählbar: Unterrichts-Modus (strukturierte Erklärungen und Übungsaufgaben), Modus2 (zu definieren; bspw. informelle Tipps und Tricks),

Online-Suche (Integration aktueller Web-Recherchen und Quellenangaben) sowie Agentic Shopping (Produktsuche mit fiktivem Bestellablauf und „Jetzt-kaufen“-Button ohne echten Kauf) (Abbildung 1 [I]). Für jeden Chat-Modus (vgl. Abbildung 1, symbolisiert durch ein Icons) ist ein eigener System-Prompt zu hinterlegen, der in der Administrationsoberfläche editierbar ist. Das RAG-basierte Hintergrundwissen darf in allen Modi auf dieselbe Sammlung bzw. Datenbank zugreifen. Im Verlauf des Projekts sollte die Möglichkeit bestehen, ein bis zwei weitere Modi in der oberen Leiste (vgl. Top Link Bar) im Rahmen der Weiterentwicklung hinzuzufügen oder zu entfernen.

- Linke Seitenleiste: Chronologische Liste früherer Chats des Nutzers (Chat-Historie). Zudem darunter ein integrierter Dateibrowser. Nutzende können eigene Dokumente hochladen, die als Hintergrundwissen für das LLM dienen (RAG) und über den Dateibrowser verwaltet werden können (Abbildung 1 [II]).
- Nutzerinnen und Nutzer sollen die Möglichkeit haben, Textdateien (z. B. .docx, .pdf, .odt, .txt, .rtf) sowie Bilddateien (z. B. .jpg, .png) hochzuladen. Diese Dateien müssen durch das System (LLM) lesbar und verarbeitbar sein. Dabei ist sicherzustellen, dass maschinengeschriebener Text auch als Foto/ Bilddatei erkannt und verarbeitet werden können.

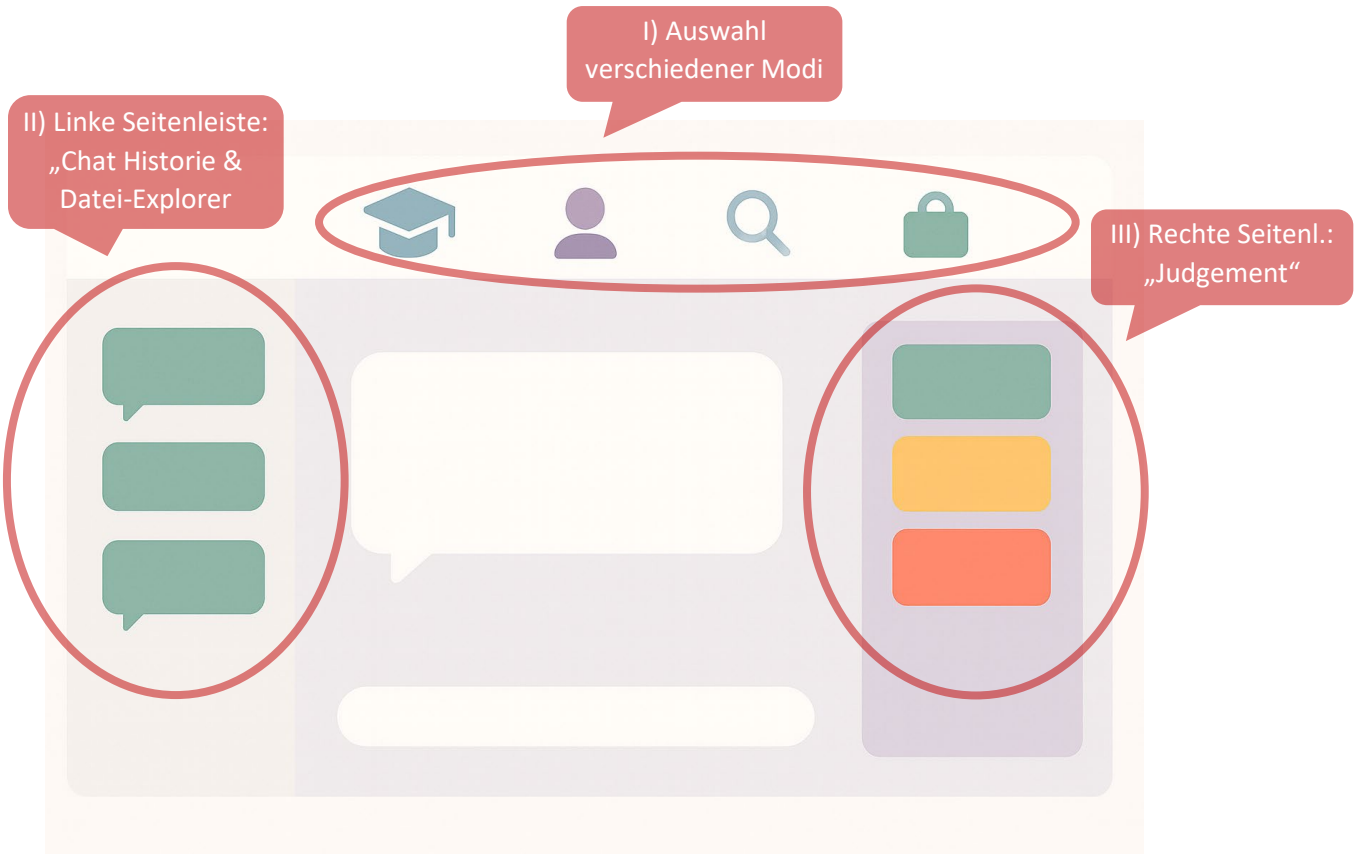


Abbildung 1: Abstraktes Layout der Benutzeroberfläche

- Rechte Seitenleiste („Judgement-Fenster“): Drei farblich codierte Bewertungsfelder zeigen die Einschätzungen zu jeder Benutzeranfrage an. Jedes Feld basiert auf einem separaten Call an ein oder zwei LLMs, der die Anfrage und die zugehörige Antwort bewertet. Die Rückmeldung

erfolgt unmittelbar im jeweiligen Feld, das sich entsprechend der Bewertung einfärbt (z. B. grün, gelb oder rot). So werden zu jeder Anfrage kurze Einschätzungen von bis zu drei Vergleichsmodellen dargestellt (Abbildung 1 [III]). Die Seitenleiste dient dazu, dass zusätzliche Modelle die im Chat erzeugten Antworten bewerten. Grundlage dieser Bewertung ist ein strukturierter Prompt, der eine klar strukturierte und knappe Einschätzung erzeugt. Dadurch erhält der Nutzer eine unterstützende Rückmeldung, die seine eigene Einschätzung der Antwort ergänzt.

- Die Seitenleisten links und rechts sind „einklappbar".
- Es müssen bis zu 3 Nutzer das System (nur Cloud) in echter Gleichzeitigkeit nutzen können. Die Antworten auf Anfragen sind innerhalb von 5 Sekunden als Streaming Response/ Typewriter Effect auszugeben, wobei nach 5 Sekunden der Stream spätestens starten sollte (Time-To-First-Token). Die 5 Sekunden gelten nicht bei Input von PDF- oder Bild-Dateien. Eine Skalierbarkeit der Plattform zur Bedienung von mehr als drei gleichzeitigen Nutzern ist nicht erforderlich.
- Auf der Plattform sollen sich bis zu 2.000 Nutzer anmelden können und diese auch nutzen können.
- Datenschutzfunktionen: Speicherung sämtlicher Chat-Verläufe ausschließlich innerhalb einer virtuell-privaten Infrastruktur eines Hosters oder auf den Testgeräten (Laptop). Nutzende können Chats löschen.

2.5 Admin-Oberfläche (Administrator)

Ein Administrator erhält ein eigenes Web-Interface zur Verwaltung des Systems. Es soll folgende Möglichkeiten bieten:

- Verwaltung der Nutzerkonten (Anlegen, Verändern, Löschen).
- Verwaltung von Dateien in der Hintergrunddatenbank (RAG) durch Hinzufügen/Entfernen von Dokumenten und Datenbanken.
- Die Dateien soll der Administrator in Form von Textdateien (z. B. .docx, .pdf, .odt, .txt, .rtf) sowie Bilddateien (z. B. .jpg, .png) hochladen können. Diese Dateien müssen durch das System (LLM) lesbar und verarbeitbar sein. Dabei ist sicherzustellen, dass sowohl maschinengeschriebener Text als auch handschriftlicher Text, soweit technisch möglich, erkannt und verarbeitet werden können.
- Eigenes Hinterlegen von System-Prompts und Verhaltenseinstellungen für die verschiedenen Modi (Unterrichts-Modus, Buddy-Modus, Online-Suche, Agentic Shopping).
- Überwachung und Einstellung von zentralen Eigenschaften der Modell-Inferenz (Hyperparameter).
- Es soll möglich sein pro Nutzer Log-Files aller Chats zu genieren. Das muss nicht innerhalb einer Admin-Nutzeroberfläche möglich sein, sondern kann über Export-Anfrage beim Auftragnehmer geschehen.

2.6 Weitere mögliche Weiterentwicklungen

Die nachfolgend genannten Funktionen gehören derzeit nicht zum Kernbestandteil des Systems. Sie können jedoch im Rahmen von Weiterentwicklungen zur Erweiterung der Benutzeroberfläche relevant werden und stellen somit Zusatzkriterien dar, die die Eignung eines Anbieters positiv beeinflussen können:

- Einbindung eines interaktiven und sprechenden Avatars zur Visualisierung eines KI-Assistenten.
- Automatische Generierung von Präsentationen und Handouts für den „Unterricht“ aus Chat- bzw. hinterlegten Lern-Inhalten.
- Implementierung einer „Teilen“-Funktion für Chat-Antworten inkl. Kommentarfunktion zwischen den Nutzern.
- Integration von Social-Media-Funktionen („Was-machen-meine-Freunde“-Sektion) für einen vertraulichen Austausch von Chat-Gesprächen unter jeweils ausgewählten anderen Nutzern der Plattform.

Die Leistungsanforderungen bilden den verbindlichen Benchmark und definieren die erforderlichen Kernkompetenzen des Auftragnehmers. Die gestalterischen Anforderungen an die Interaktionsoberflächen können sich im Verlauf des Projekts weiterentwickeln und zu neuen Detailanforderungen führen. Diese sollen auf Seiten des Auftragnehmers jedoch keine zusätzlichen Kompetenzen erfordern, die über die bereits in den übrigen Anforderungen abgedeckten Fähigkeiten hinausgehen oder das vereinbarte Budget überschreiten.

3. Zeit- und Budgetanforderungen

3.1 Phasenplan und Budget

Der Gesamtzeitraum des Auftrags erstreckt sich über 23 Monate (März 2026 – einschl. Januar 2028). Das Gesamtbudget beträgt 70 000 € brutto. Die Mittel sind nach dem 70–20–10-Prinzip über die drei Entwicklungsphasen des Projektes aufzuteilen: 70 % des Budgets für die initiale Entwicklung und Betrieb (Phase 1), 20 % für größere Weiterentwicklungen und Fehlerbehebungen (Phase 2) sowie 10 % für kleinere Verbesserungen (Phase 3).

1. **Phase 1 – Grundentwicklung** (März 2026 – Juli 2026) **+ Betrieb** (März – einschl. Januar 2028) (70% des Budgets): Entwicklung des Kernsystems, Bereitstellung der Cloud-Infrastruktur, Einrichtung der lokalen Testsysteme und Anpassung der LLMs an die finanziellen Lerninhalte.
2. **Phase 2 – Weiterentwicklung** (November 2026 – März 2027, 20 % des Budgets): Integration der optionalen Funktionen, Durchführung von Optimierungen sowie Fehlerbehebungen basierend auf Nutzertests.
3. **Phase 3 – kleinere Weiterentwicklungen** (≈ Juli 2027 – Oktober 2027, 10 % des Budgets): Implementierung kleinerer Verbesserungen und Abschlusstests.

Für die Weiterentwicklungen in Phase 2 und 3 ist im Angebot ein Kontingent an Personenstunden auszuweisen, das sich am verfügbaren Budget orientiert. Je mehr Stunden für das gegebene Budget

angeboten werden, desto besser fällt die Bewertung des Anbieters aus. Die Kalkulation soll als Mischkalkulation erfolgen und Mitarbeiterinnen und Mitarbeiter mit Kompetenzen in den Bereichen Benutzeroberfläche, Sprachmodelle und RAG-Datenbanken berücksichtigen.

Die in Phase 2 und 3 umzusetzenden Arbeitspakete werden zu gegebener Zeit in Anlehnung an das Scrum-Vorgehensmodell aus dem Product Backlog ausgewählt. Die Priorisierung erfolgt auf Grundlage der Einschätzung des Entwicklerteams hinsichtlich erforderlicher Skills, Zeit und Budget und wird in Abstimmung mit der Projektleitung der Hochschule Bonn-Rhein-Sieg verbindlich festgelegt.

3.2 Support und Gewährleistung im Rahmen des Projekts

Der Auftragnehmer gewährleistet die Funktionsfähigkeit des Systems während des gesamten Projektzeitraums. Fehler und Sicherheitslücken sind unverzüglich zu beheben.

Es ist ein qualifizierter Support in deutscher und englischer Sprache den Ansprechpartnern des Forschungsprojekts der Hochschule Bonn-Rhein-Sieg zu stellen. Bei größeren Ausfällen muss eine Wiederherstellung des Betriebs binnen zwei Werktagen erfolgen.

4. Anforderungen an das Angebot

Der Bieter hat die angebotene Lösung transparent und nachvollziehbar zu beschreiben. Die im Leistungsverzeichnis angegebenen Mindestanforderungen (siehe Sektion 6: Zuschlagskriterien) sind zwingend zu erfüllen. Eine Nichterfüllung führt zum Ausschluss des Angebotes. Die im Leistungsverzeichnis angegebenen Zusatzkriterien (ZK) werden bei der Bewertung des Angebotes berücksichtigt.

Das Angebot ist in deutscher Sprache abzugeben.

Hinweis:

Bitte achten Sie darauf, dass Sie für die vorgenannten Anlagen zum Angebot kein Geschäftspapier verwenden, auf denen ihre Allgemeinen Geschäftsbedingungen aufgeführt sind oder auf diese verwiesen wird. Die AGB des Bieters haben – auch wenn sie dem Angebot beigefügt werden – keine Wirksamkeit.

5. Vertragsbedingungen

Es gelten die beigefügten Vertragsbedingungen der Hochschule Bonn-Rhein-Sieg zusammen mit den Zusätzlichen Vertragsbedingungen des Landes NRW (ZVB-NRW).

Dem Angebot ist ein Entwurf über einen Dienstleistungsvertrag beizufügen.

Die Hochschule Bonn-Rhein-Sieg soll an der Software ein einfaches, unentgeltliches, zeitlich, räumlich und inhaltlich unbeschränktes Nutzungsrecht, einschließlich des Rechts zur Bearbeitung, Vervielfältigung, Verbreitung und öffentlichen Zugänglichmachung erhalten.

Zahlungsbedingungen:

30 Tage netto monatlich nach Rechnungsstellung und nachgewiesener Leistung des Auftragnehmers oder in Absprache anderer Zahlungsmodalitäten mit der Hochschule.

6. Zuschlagskriterien

Der Zuschlag erfolgt auf das wirtschaftlichste Angebot unter Berücksichtigung der Mindestanforderungen (Erfüllung zwingend, jedoch in ihrer Ausprägung auch mit Punkten zu bewerten) sowie der Zusatzkriterien. Das Angebot mit der höchsten Gesamtpunktzahl erhält den Zuschlag.

Die Punktevergabe orientiert sich bei einem festgelegten Maximalpreis von 70.000 € brutto am angebotenen Leistungsumfang sowie der vorgesehenen Anzahl an Personenstunden für Weiterentwicklungen und zusätzlichen Kompetenzen des Anbieters (vgl. Abschnitt 2.6).

Für die Mindestanforderungen stehen insgesamt 100 Punkte, für die Zusatzkriterien weitere 30 Punkte zur Verfügung. Die Erfüllung der Mindestanforderungen wird qualitativ auf einer Skala von 1 bis 10, 1 bis 15 oder 1 bis 20 Punkten bewertet:

- MA6: Anzahl der angebotenen Personenstunden im Wettbewerbsvergleich
- MA1 bis 5 sowie MA7 bis 8: Mehrwert des Angebots gegenüber konkurrierenden Angeboten

MA/ZK	Kriterium	Zu erreichende Punktzahl
MA1	2.1 Open Source, Cloud und On-Premise	10
MA2	2.2 Cloud-Infrastruktur	10
MA3	2.3 Sprachmodell & RAG-Datenbank	10
MA4	2.4 Benutzeroberfläche	10
MA5	2.5 Admin-Oberfläche (Administrator)	10
MA6	Anzahl der Personenstunden für Weiterentwicklung	20
MA7	Ressourceneffizienz durch Lauffähigkeit auf „kleinen“ GPUs (vgl. RTX 6000; RTX 4090; A100) unter Verwendung von ebenfalls kleinen LLMs (bspw. 10B oder sogar <= 1B)	15
MA8	Drei Referenzen aus dem Bereich Open Sourcen KI Entwicklung sowie Erfahrung in domänenspezifischem Finetuning von Modellen	15
ZK1	Nachweisliche Erfahrung in Projekten mit öffentlichen Einrichtungen evtl. sogar Forschungsprojekten	5
ZK2	2.6 a) Avatar	5
ZK3	2.6 b) Generierung von Handouts und Präsentationen	5
ZK4	2.6 c) Teilen-Funktion	5
ZK5	2.6 d) Social-Media-Funktion	5
ZK6	Eigene Text-to-Speech/ Speech-to-Text/ Speech-to-Speech Modelle	5